

## 메타 러닝을 통한 Wi-Fi 센싱의 도메인 독립성 향상 연구

표지성, 최재혁

가천대학교 AI·소프트웨어학부

{p990301, jchoi}@gachon.ac.kr

## A Study on Domain Independent Wi-Fi Sensing via Meta-learning

Jisung Pyo, Jaehyuk Choi

School of Computing, Gachon University

## 요약

최근 Wi-Fi 센싱을 통한 인간 행동 인식 기술(Human Activity Recognition)은 딥러닝 기술을 활용하여 정확도를 비약적으로 향상시켰다. 그러나, 이 기술은 대상 행동들에 대한 환경 변화의 무선채널의 상태를 측정 후 학습하는 태생적 접근으로 학습된 모델의 적용이 측정된 환경 또는 도메인에 국한되는 한계가 있었다. 본 연구에서는 트랜스포머 모델과 메타 러닝을 결합한 방법을 제안하여 이러한 Wi-Fi 센싱의 도메인 종속성 문제를 극복하며 훈련 데이터세트에 포함되지 않은 클래스 데이터까지 모델이 분류하는 방법을 제안한다.

## 1. 서론

오늘날 인간 활동 인식을 위해 카메라 기반과 웨어러블 기반 기술이 주로 사용되고 있다. 카메라 기반 방식은 사람의 움직임을 이미지나 비디오를 통해 정확하게 구분할 수 있지만 개인 정보 유출 및 카메라의 촬영 범위 내에서 행동해야 한다. 또한 웨어러블 기반의 경우는 사용자의 다양한 생체 신호를 종합하여 행동을 구분할 수 있지만 사용자가 웨어러블 기기의 추가 비용 지출 및 불편을 가질 수 있다. 기존 인간 활동 인식 접근의 문제점으로 인하여 최근 Wi-Fi를 이용한 활동 인식에 관심이 높아지고 있다. 이는 channel state information (CSI) 데이터를 기반으로 진행되며 이를 Wi-Fi 센싱이라 한다. CSI 데이터는 물리 계층에서 수신기가 채널로부터 수신한 신호의 세부적인 특성과 채널의 상태에 대한 정보를 포함하고 있다. 회절, 반사 및 산란 후 물리적 환경에서 무선 신호가 전파되는 방식까지 통신 링크에 영향을 주며 CSI 데이터의 변형을 불러일으킨다. 따라 하나의 환경에서 수집된 CSI 데이터는 같은 행동일지라도 타 환경과 다르게 측정되게 되며 이를 도메인 종속성이라 한다.

딥러닝 기반 Wi-Fi 센싱에서는 모델을 학습시키기 위해 많은 양의 데이터가 필요하다. 현실에서 많은 양의 데이터를 수집하는 것은 시간과 노력을 많이 요구할 뿐만 아니라 모델의 확장성도 제한할 수 있게 된다. 이뿐만 아니라 도메인 종속성으로 인하여 학습된 환경이 아닌 다른 환경에서 모델은 정확한 예측을 할 수 없게 되며 이는 Wi-Fi 센싱의 확장성 및 일반화 성능을 저하한다. 또한 딥러닝의 모델 선택은 센싱 결과에 영향을

직접 줄 수 있는 중요한 부분으로 Convolutional Neural Network (CNN) 과 Recurrent Neural Network (RNN) 등 다양한 신경망 구조를 고려할 수 있다. CNN은 입력의 크기를 고정해야 하는 문제 및 시계열 데이터 처리의 어려움이 존재하게 되며, RNN은 모델의 크기가 커질수록 연산 비용 증가 및 장기 의존성 문제가 발생한다.

본 연구에서는 Wi-Fi 센싱 모델의 확장성 및 일반화를 높이기 위해 트랜스포머 모델과 메타 러닝을 조합한 방식에 대해서 제안한다. 제안한 방식은 시계열 데이터의 특성을 잘 이해하고 다양한 환경에서 일반화 능력에 대해 향상할 수 있으며 이를 통해 정확하고 신뢰할 수 있는 Wi-Fi 센싱 시스템을 구축할 수 있다.

## II. 모델 확장성 및 일반화 검증

본 논문에서는 Wi-Fi 센싱의 도메인 종속성으로 인한 지도 학습의 문제점을 지적하고 문제점 해소를 위한 메타 러닝 도입을 목표로 한다. 이뿐만 아니라 다양한 모델에 메타 러닝을 적용하여 모델 일반화를 검증하고 학습 데이터에 포함되지 않은 행동 클래스에 대해서까지 확장이 가능한지 검토한다.

## 1) 시스템 설계

그림 1은 메타 러닝을 위한 본 실험의 전반적인 구조에 대해서 나타내고 있다. 메타 러닝은 에피소드라고 불리는 샘플링 된 미니 배치를 활용하

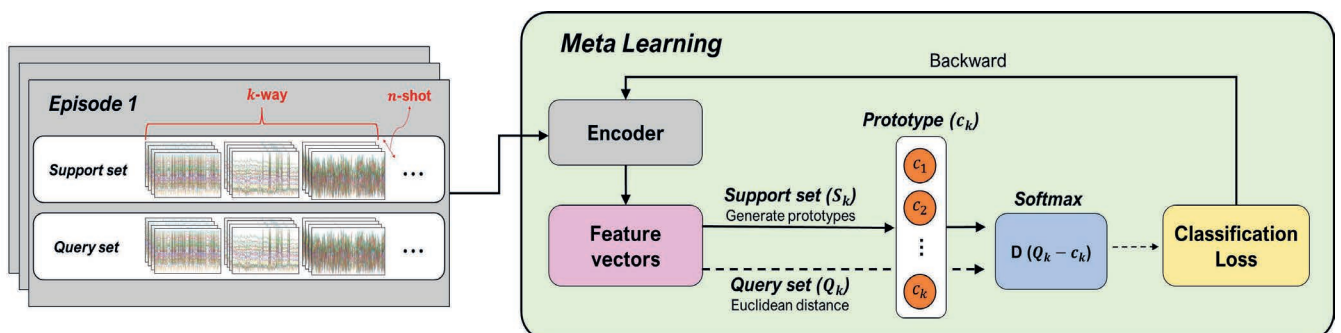


그림 1 시스템 설계

여 학습을 진행하게 되며 각 에피소드의 support set( $S_k$ )과 query set( $Q_k$ )를 Encoder의 입력으로 넣어 특징 벡터를 추출하게 된다. 특징 벡터를 바탕으로 임베딩 공간에 대한 입력의 비선형 매핑을 학습하고 다음과 같은 수식에 의해 임베딩 공간의 각 클래스에 속한 평균 벡터를 의미하는 prototype( $c_k$ )을 형성하게 된다. [1]

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} \text{Encoder}(x_i)$$

임베딩 공간의 prototype과 query set을 유클리드 거리 기반의 소프트맥스 통하여 query set에 대한 분류를 수행한다.

## 2) 데이터 세트

실험을 위해 ReWiS[2] 데이터세트와 수집 데이터세트를 기반으로 검증을 진행하였으며 CSI 수집을 위해 Nexmon CSI 도구를 활용하여 5GHz의 부반송파를 수집하였다. 메타 러닝이 부반송파의 수와 관계없이 유연하게 동작함을 확인하기 위해 두 데이터 세트의 부반송파 수를 각각 256개, 64개를 선택하였다.

## 3) 실험 결과

### 3.1) 도메인 종속성으로 인한 지도 학습의 문제점

CSI 데이터는 주변의 환경에 의해 변화하므로 학습을 위해 수집된 환경이 아닌 다른 환경에서 Wi-Fi 센싱의 정확한 예측이 불가능하게 된다. ReWiS 데이터세트를 통해 환경 변화에 따른 지도 학습의 감소 정도를 파악하였으며 그림 2에 나타났다. 그림 2를 통해 학습과 테스트가 동일하지 않은 환경일 경우, 동일한 환경에서 진행하는 경우와 대비하여 모델이 낮은 정확도를 보여주었다. 이는 Wi-Fi 센싱이 가지는 환경 종속성으로 인하여 모델이 데이터에 대해 학습이 제대로 이루어지지 않았으며 그 결과 환경 변화가 발생 시 정확한 예측 결과를 도출할 수 없었다.




그림 2 ReWiS 데이터세트 지도 학습 결과

### 3.2) 메타 러닝 적용을 통한 모델 일반화

메타 러닝은 모델이 다른 작업을 학습하고 그 학습 경험을 토대로 새로운 작업에 빠르게 적응하여 일반화 능력을 갖출 수 있도록 해준다. 그림 3은 다양한 모델에 메타 러닝을 적용하였으며 ReWiS A1 환경에서 학습하고 A3 환경에서 테스트를 진행한 결과를 나타내고 있다. 이와 더불어 support set과 query set 크기의 변화에도 같은 성능을 보장하는지를 확인하였다. 기존 지도 학습에 대비하여 메타 러닝의 적용하여 다른 환경에 대한 모든 모델이 정확도 상승을 보여주었다. 특히 4가지의 모델 중 트랜스포머는 다양한 support set과 query set 사이의 조합에서 거의 같은 성능을 보여주고 있다. 하지만 LSTM과 CNN의 경우 조합의 변화에 따라서 민감하게 반응하는 것을 확인하였다. 이는 트랜스포머와 메타 러닝이 조

합을 통하여 Wi-Fi 센싱의 도메인 종속성을 해소하며 모델의 일반화 성능을 보장한다는 것을 알 수 있다.




그림 3 Support set과 Query set 변화에 따른 모델 정확도

### 3.3) 학습에 포함되지 않은 클래스에 대한 모델 확장성 보장

메타 러닝과 트랜스포머의 확장성을 평가하기 위해 학습 데이터세트에 포함되지 않은 클래스에 대한 실험을 진행했으며 분류 결과를 확인하기 위해 표 1과 같이 오차 행렬을 나타냈다. 수집 데이터세트를 활용하여 일부 클래스(empty, stand, walk)의 데이터만을 가지고 모델 학습을 진행하였다. 테스트 과정에서는 학습에 포함된 클래스 데이터뿐만 아니라 sit 클래스의 데이터를 추가하여 모델이 학습하지 않은 데이터에 대해서 분류할 수 있는지 검증하였다. 메타 러닝을 통해 학습한 결과 모델은 높은 분류 성능을 보이며 학습에 포함되지 않은 클래스에 대해서도 분류하였다.

Predict \ True	empty	stand	walk	sit
empty	100%	0%	0%	0%
stand	0%	91.66%	0%	8.33%
walk	0%	0%	100%	0%
sit	0%	0%	0%	100%

표 1 학습에 포함되지 않은 클래스 검증 오차 행렬

## III. 결론

본 논문에서는 메타 러닝과 트랜스포머를 기반한 Wi-Fi 센싱 시스템 확장성과 일반화에 대하여 증명하였다. 메타 러닝을 통하여 모델의 일반화 성능을 높일 수 있었으며 CSI 데이터의 도메인 종속성 해소를 끌어낼 수 있었다. 트랜스포머의 사용은 입력 시퀀스를 보존함으로써 많은 데이터 처리에도 일관성 있는 모델 정확도를 보였다. 이와 더불어 학습 시 포함되지 않은 클래스 데이터까지도 높은 분류 성능을 보여주었다. 이는 데이터를 수집하는 과정에서 데이터 수집 비용을 감소시킬 수 있을 것으로 예상되며 추후 Wi-Fi 센싱 시스템의 유연함을 사용자에게 경험시켜 줄 수 있을 것으로 생각한다.

## 참고 문헌

- [1] Snell, J., Swersky, K., & Zemel, R. (2017). Prototypical networks for few-shot learning. *Advances in neural information processing systems*, 30.
- [2] Bahadori, N., Ashdown, J., & Restuccia, F. (2022, June). ReWiS: Reliable Wi-Fi sensing through few-shot multi-antenna multi-receiver CSI learning. In *2022 IEEE 23rd International Symposium on a World of Wireless, Mobile and Multimedia Networks (WoWMoM)* (pp. 50-59). IEEE.